

¿Las máquinas escuchan?

IA, señales y música

Dr. Omar Velázquez López

IIMAS, UNAM

Día GAIA · Club de Inteligencia Artificial · ESCOM-IPN · 11 de septiembre de 2026

1950

¿Pueden pensar las máquinas?

Alan Turing, *Computing Machinery and Intelligence*
Mind, vol. LIX, octubre de 1950

Hoy

¿Pueden **escuchar** las máquinas?



Escuchen esto

Ustedes oyeron música. Más Adelante sabremos qué recibe la máquina.

¿Qué es Music Information Retrieval?

Extraer información musical del audio. Vive entre el procesamiento de señales, el aprendizaje automático y la musicología.

Clasificación de género	¿De qué tipo es esta música?
Transcripción automática (AMT)	¿Qué notas están sonando?
Separación de fuentes	¿Puedo aislar la voz del acompañamiento?
Tempo y compás	¿A qué velocidad va, dónde cae el pulso?
Identificación de versiones	¿Es la misma canción que aquella?
Recomendación	¿Qué más me va a gustar?

Hoy hacemos dos de estas. La marcada es en la que he estado trabajando.

Lo que vamos a ver

¿Quién diseña la representación? Al final volveremos a esta tabla.

Generación	Representación	Clasificador
Primera	—	—
Segunda	—	—
Tercera	—	—




[github.com/omarvlo/
maquinas-escuchan-gaia2026](https://github.com/omarvlo/maquinas-escuchan-gaia2026)

*Todo lo que van a ver está aquí.
No hace falta que lo ejecuten ahora.*

Esto es todo lo que recibe




La señal completa



22,050

números por segundo


20 ms: no dice nada útil



0

nociones de nota

El mismo instante, en frecuencia




0

nociones de compás

El tiempo lo esconde. La frecuencia lo muestra.


Fourier: pintar la música

Espectrograma: cada franja horizontal es un armónico



Cada franja horizontal es un armónico. Ya se ve la progresión de acordes.

Todo sistema de MIR tiene dos mitades



Toda la investigación de las últimas dos décadas se fue a la derecha.

Esta charla va sobre si eso fue buena idea.

El oído no es un analizador de Fourier uniforme


El espectrograma reparte sus canales linealmente: la misma resolución en 100 Hz que en 7000 Hz. El oído no funciona así.

Mel	1937	Experimentos de percepción de altura con oyentes humanos
ERB	1990	Ancho de banda de los filtros auditivos (Glasberg y Moore)
Greenwood	1961	Posición física a lo largo de la cóclea
Lineal	—	Sin modelo auditivo. Referencia


Seguimos usando una escala de 1937 en los modelos de 2026.

¿Dónde pone cada escala sus canales?

Dónde coloca sus 40 canales cada escala




Resolución en el registro grave



Ninguna mente. Reparten distinto — y el piano vive en el grave.

El mismo audio, visto por tres bancos

Mismo audio, mismos 40 canales, tres repartos distintos



La versión lineal deja el registro grave aplastado contra el eje. Las auditivas lo despliegan.

Escuchemos el canal 6

MEL

294 – 359 Hz

canal 6



GREENWOOD

155 – 185 Hz

canal 6



Mismo número de canal. Misma señal. Contenido distinto.



Sonido original



Pruébenlo con su música

github.com/omarvlo/maquinas-escuchan-gaia2026

Cambien una línea y oigan el canal 6 de lo que quieran.

Fin de la primera generación


Generación	Representación	Clasificador
Primera	diseñada a mano	diseñado a mano
Segunda	—	—
Tercera	—	—

¿Y si dejamos que la máquina aprenda sola?

Lo único que le damos


Un espectrograma mel por fragmento. Sin reglas, sin teoría musical, sin explicaciones.

Un espectrograma mel por clase — esto es todo lo que recibe la red



Nadie le explica qué es el jazz. Solo le decimos cuál es cuál.

La red entrena



Menos de un minuto en una GPU gratuita.

¿Qué tan bien clasifica?

Acierta

61.6 %

de los fragmentos

Al azar acertaría

10 %

con 10 clases

Mejor que adivinar


6.2×

Pero "acierta 6 veces más que al azar" no dice QUÉ aprendió.


1 · Su espacio interno se reorganizó

La representación interna de la red, proyectada a 2D

ANTES de entrenar · separabilidad 0.66




DESPUÉS de entrenar · separabilidad 1.94




Nadie le dijo dónde poner cada género. La geometría es consecuencia de aprender.

2 · Sus errores tienen sentido musical




¿A ustedes también les cuesta distinguir esos dos?

3 · Dónde aprendió a escuchar



Nadie le dijo que mirara ahí. Lo encontró sola.

¿Y si solo le faltaban datos?



Duplicar de 150 a 300 dio 10 puntos. De 300 a 600 dio 3. Se está aplanando.

Fin de la segunda generación

Generación	Representación	Clasificador
Primera	diseñada a mano	diseñado a mano
Segunda	diseñada a mano	aprendido
Tercera	—	—

Automatizamos el clasificador. La entrada sigue hecha a mano.

Ya ni siquiera hace falta entrenar

1

Modelo preentrenado

Escuchó miles de horas de audio sin una sola etiqueta. Nadie le dijo qué era cada cosa.

2

Linear probe · sonda lineal

Congelamos el modelo, le pedimos sus representaciones, y encima ponemos el clasificador más simple que existe.

Si con el clasificador más tonto basta, es que el trabajo ya estaba hecho.

Preguntémosle cuál es su front-end

Front-end de m-a-p/MERT-v1-95M

leído de la configuración del propio modelo, no afirmado por mí

feature_size	1
sampling_rate	24000
num_mel_bins	– no existe –

feature_size = 1 → entra la forma de onda cruda.
Este modelo NO usa un banco de filtros mel.

Ningún banco de filtros mel. MERT entra por la forma de onda cruda.

Nunca vio una etiqueta


Nunca vio una etiqueta, y aun así separa las clases
separabilidad 0.95



Y aun así los separa.

Los dos, lado a lado

Mismo conjunto de prueba: no solo cuánto fallan, sino en qué



Accuracy parecido no significa errores parecidos.

¿Qué se automatizó?

Generación	Representación	Clasificador
Primera	diseñada a mano	diseñado a mano
Segunda	diseñada a mano	aprendido
Tercera	aprendida — pero supervisada por una CQT	aprendido sin etiquetas

La CQT es de 1991, y la eligió un humano.

El front-end no desapareció. Cambió de lugar.

De dónde salió esta pregunta

Lo que casi nunca se cuenta:

El artículo

"Beyond the Mel Scale" — rechazado dos veces

La propuesta posdoctoral

Rechazada en varias convocatorias

El diagnóstico de los revisores

Comparar un banco contra otro no era la pregunta interesante

Tenían razón. La pregunta era otra.

Y esta es la pregunta

¿El front-end auditivo es preprocesamiento neutro,
o decide qué evidencia acústica queda disponible para el modelo?

Nuestro trabajo en el IIMAS-UNAM

Cuatro front-ends

Mel, ERB, Greenwood y una escala coclear (aplicada a transcripción en Velázquez et al., 2022), con el mismo número de canales

Una tarea

Transcripción musical automática sobre piano

Otra medida

No accuracy: dónde queda localizable la evidencia cuando el modelo falla

La pregunta pasa de si pueden escuchar a cómo escuchan, y si eso importa.

¡Gracias!

Correo

omarvlo@comunidad.unam.mx

LinkedIn

linkedin.com/in/omarvlo

GitHub

github.com/omarvlo/maquinas-escuchan-gaia2026



El notebook de hoy